



Taller 2
Redes Neuronales

Joan Sebastian Borja Mosquera - 120289

Dana Katerin Contreras Martinez - 122290

Maria Alejandra Rojas Paez - 122374

Facultad de Ingeniería Industrial

Universidad ECCI

Sistemas Avanzados de Producción

12 de Abril del 2026

Introducción.

Este documento desarrolla la aplicación de metodologías de aprendizaje automático para la resolución de dos desafíos críticos en el ámbito de la ingeniería industrial: la planeación de la movilidad urbana y el mantenimiento predictivo de activos. A través del conjunto de datos Capital Bikeshare, se analiza la demanda de transporte multimodal en Washington D.C., un sistema donde la variabilidad climática y estacional exige modelos capaces de capturar interacciones no lineales para evitar ineficiencias logísticas. Paralelamente, mediante el dataset AI4I 2020, se aborda la detección de fallos industriales bajo condiciones de desbalance de clases, un escenario donde la precisión simple resulta insuficiente para la toma de decisiones. El flujo de trabajo abarca desde la rigurosidad matemática de la regularización Ridge hasta el despliegue de redes neuronales (MLP), consolidando una arquitectura analítica orientada a optimizar la disponibilidad operativa y reducir costos de producción.

Desarrollo Técnico y Análisis Crítico e Interpretación.

Punto 3 - Fase 1.

Fase 1: Regularización Ridge — Derivación Matemática

La Regresión Ridge agrega una penalización L2 a la función de costo de Mínimos Cuadrados Ordinarios (OLS), controlando la magnitud de los coeficientes y mejorando la generalización del modelo cuando existe multicolinealidad o alta dimensionalidad.

Fase 1.1 Representación Vectorial

La función de costo escalar dada en el enunciado se escribe en notación matricial compacta.

La suma de residuos al cuadrado se expresa como producto interno y la penalización como la norma al cuadrado del vector β :

Forma escalar (dada en el enunciado):

$$J(\beta) = \sum_i (y_i - \beta_0 - \sum_j \beta_j x_{ij})^2 + \lambda \sum_j \beta_j^2$$

Forma matricial equivalente:

$$J(\beta) = (Y - X\beta)^T(Y - X\beta) + \lambda\beta^T\beta$$

Donde:

$Y \in \mathbb{R}^n \rightarrow$ Vector columna de respuestas observadas

$X \in \mathbb{R}^{n \times p} \rightarrow$ Matriz de diseño (incluye columna de 1s para β_0)

$\beta \in \mathbb{R}^p \rightarrow$ Vector de parámetros a estimar

$\lambda \geq 0 \rightarrow$ Híper Parámetro de regularización

La suma $\sum_j \beta_j^2$ es el producto interno $\beta^T\beta = \|\beta\|^2$. Esto permite tratar la penalización como un término algebraico matricial diferenciable, manteniendo la forma cuadrática de $J(\beta)$ y garantizando la existencia de un único mínimo global.

Fase 1.2 Expansión de la Forma Cuadrática

Se desarrolla el producto $(Y - X\beta)^T(Y - X\beta)$ usando las propiedades de la transpuesta $(AB)^T = B^TA^T$, y se combina con el término de penalización

$$\begin{aligned} & \text{Expandiendo } (Y - X\beta)^T(Y - X\beta): \\ & = Y^TY - Y^T(X\beta) - (X\beta)^TY + (X\beta)^T(X\beta) \end{aligned}$$

$$\begin{aligned} \text{Usando } (X\beta)^T &= \beta^TX^T \text{ y } Y^T(X\beta) = (X\beta)^TY \text{ (ambos son escalares):} \\ & = Y^TY - 2\beta^TX^TY + \beta^TX^TX\beta \end{aligned}$$

$$\begin{aligned} & \text{Sumando el término de penalización } \lambda\beta^T\beta: \\ J(\beta) &= Y^TY - 2\beta^TX^TY + \beta^TX^TX\beta + \lambda\beta^T\beta \end{aligned}$$

$$\begin{aligned} & \text{Factorizando los términos cuadráticos en } \beta: \\ J(\beta) &= Y^TY - 2\beta^TX^TY + \beta^T(X^TX + \lambda I)\beta \end{aligned}$$

El resultado es una forma cuadrática en β . Cuando $(X^TX + \lambda I)$ es definida positiva (lo cual se garantiza para $\lambda > 0$), la función $J(\beta)$ es estrictamente convexa y tiene un único mínimo global.

Fase 1.3 Condición de Primer Orden

Se calcula la derivada matricial $\partial J(\beta)/\partial\beta$ aplicando las reglas de diferenciación de formas lineales y cuadráticas, y se iguala al vector cero para encontrar el mínimo:

Reglas de derivación matricial aplicadas:

$$\partial/\partial\beta [\beta^Ta] = a \quad (\text{forma lineal en } \beta)$$

$$\partial/\partial\beta [\beta^TA\beta] = 2A\beta \quad (\text{forma cuadrática, } A \text{ simétrica})$$

Aplicando término a término:

$$\partial/\partial\beta [Y^TY] = 0 \text{ (constante en } \beta)$$

$$\partial/\partial\beta [-2\beta^TX^TY] = -2X^TY$$

$$\partial/\partial\beta [\beta^T(X^TX + \lambda I)\beta] = 2(X^TX + \lambda I)\beta$$

Gradiente completo:

$$\partial J(\beta)/\partial\beta = -2X^TY + 2(X^TX + \lambda I)\beta$$

Iguando a cero (condición necesaria y suficiente de mínimo):

$$-2X^TY + 2(X^TX + \lambda I)\beta = 0$$

$$(X^TX + \lambda I)\beta = X^TY$$

Fase 1.4 Solución Cerrada

Despejando β de la ecuación normal con regularización, pre-multiplicando ambos lados por la inversa de $(X^TX + \lambda I)$:

De la condición de primer orden:

$$(X^TX + \lambda I)\beta = X^TY$$

Pre-multiplicando ambos lados por $(X^TX + \lambda I)^{-1}$:

$$(X^TX + \lambda I)^{-1} (X^TX + \lambda I)\beta = (X^TX + \lambda I)^{-1} X^TY$$

La inversa anula la matriz ($A^{-1}A = I$):

$$I\beta = (X^TX + \lambda I)^{-1} X^TY$$

donde I es la matriz identidad de dimensión $p \times p$ (misma dimensión que X^TX). Esta inversa existe para todo $\lambda > 0$, independientemente de si X^TX es singular.

Preguntas Conceptuales Fase 1.

Para finalizar esta primera fase, se procede a dar solución a las preguntas conceptuales:

- 1. Sobre la Invertibilidad: ¿Por qué la suma λI garantiza que la matriz resultante sea invertible incluso si X^TX es singular?**

X^TX es una matriz semidefinida positiva, lo que significa que puede tener valores propios iguales a cero. Esto ocurre cuando las columnas de X son linealmente dependientes (multicolinealidad) o cuando hay más variables que observaciones ($p > n$). En ambos casos X^TX no tiene inversa.

En términos geométricos, λI “infla” la matriz en todas las direcciones del espacio de parámetros, eliminando las direcciones planas (degeneradas) que causaban la

singularidad. En el contexto del dataset Bike Sharing, donde variables como temperatura, sensación térmica y humedad están fuertemente correlacionadas, esta propiedad es crítica para obtener un estimador estable y único.

2. **Efecto del Parámetro λ : ¿Qué sucede con el modelo cuando $\lambda \rightarrow 0$? ¿Y cuando $\lambda \rightarrow \infty$?**

Cuando es $\lambda \rightarrow 0$

La penalización desaparece y el estimador se reduce al de Mínimos Cuadrados Ordinarios. Coeficientes grandes, máxima flexibilidad, alta varianza. El modelo tiende a memorizar el ruido de los datos de entrenamiento.

Cuando $\lambda \rightarrow \infty$

La penalización domina y fuerza todos los coeficientes hacia cero. El modelo se vuelve extremadamente simple, pierde capacidad de ajuste. Se elimina la varianza pero se introduce sesgo severo

Explicado en términos de Sesgo -Varianza

Trade-off Sesgo-Varianza:

$$\text{Error Total} = \text{Sesgo}^2 + \text{Varianza} + \text{Ruido irreducible}$$

λ pequeño $\rightarrow$ sesgo bajo, varianza alta (sobreajuste)

λ óptimo $\rightarrow$ balance entre sesgo y varianza

λ grande $\rightarrow$ sesgo alto, varianza baja (subajuste)

Fase 2 Optimización Numérica y Descenso de Gradiente.

Se utilizó la función de Himmelblau $f(x,y) = (x^2+y-11)^2 + (x+y^2-7)^2$, que posee cuatro mínimos locales, como superficie de prueba para el algoritmo de Descenso de Gradiente. Se realizaron cuatro experimentos variando la tasa de aprendizaje η y el punto de inicio.

1. $\eta = 0.5$ — Tasa de aprendizaje alta (overshooting)




Figura [1]: Experimento A: $\eta = 0.5$ — el punto verde queda bloqueado lejos del mínimo

La trayectoria parte desde el origen y se detiene aproximadamente en (2, 2), sin alcanzar ninguno de los cuatro mínimos. El paso $\eta \cdot \nabla f$ es tan grande que el algoritmo frena su avance prematuramente, quedando atascado en una zona de valor elevado — overshooting parcial.

2. $\eta = 1 \times 10^{-7}$ — Tasa de aprendizaje extremadamente baja




Figura 2. $\eta = 1e-7$ — trayectoria invisible, sin desplazamiento

La trayectoria es invisible en ambas vistas: el punto verde permanece en (0, 0.1), idéntico al punto de inicio. Con pasos del orden de 10^{-7} , las 1000 iteraciones desplazan el punto una distancia insignificante. Necesitaría $\sim 10^8$ iteraciones para alcanzar el mínimo.

3. Punto inicial [6.0, -6.0] — esquina inferior derecha




Figura 3. Inicio [6,-6] — converge al mínimo inferior derecho ($\sim 3, -2$)

Partiendo desde $[6.0, -6.0]$, la trayectoria desciende en línea directa y converge al mínimo inferior derecho ($\sim 3, -2$). Trayectoria limpia y sin oscilaciones, confirmando que $\eta = 0.0001$ es adecuado para esta superficie.

4. Punto inicial $[-5.0, 5.0]$ — esquina superior izquierda




Figura 4. Inicio [-5,5] — converge al mínimo superior izquierdo ($\sim -3, 3$)

Partiendo desde $[-5.0, 5.0]$, el algoritmo converge al mínimo superior izquierdo ($\sim -3, 3$), radicalmente diferente al Experimento C a pesar de usar exactamente la misma configuración de η . Esto demuestra la dependencia crítica del punto de inicio.

Preguntas conceptuales Fase 2.

Para finalizar esta segunda fase, se da solución a las preguntas conceptuales:

- 1. El fenómeno de 'Overshooting' — Explique físicamente qué ocurre cuando el paso ($\eta \cdot \nabla f$) es más grande que la distancia al mínimo. ¿Cómo se visualiza esto en el gráfico de curvas de nivel?**

El overshooting ocurre cuando el producto $\eta \cdot \nabla f$ (el tamaño del salto) es mayor que la distancia real al mínimo. En lugar de acercarse al fondo del valle, el algoritmo salta al lado opuesto, terminando en una zona de mayor error. Si se repite en cada iteración, la trayectoria zigzaguea entre las paredes del valle sin converger.

- 2. Si el algoritmo se detiene en la iteración con 1000 pero aún se encuentra lejos del mínimo, ¿qué estrategia es mejor: aumentar el número de iteraciones o ajustar la tasa de aprendizaje? Justifique su respuesta.**

La estrategia correcta siempre es ajustar η , no aumentar las iteraciones. En el Exp. B, pasar de 1000 a 100,000 iteraciones habría desplazado el punto 100 veces más — todavía a una distancia enorme del mínimo. La prioridad es calibrar η mediante learning rate scheduling, line search o Adam.

- 3. En un problema de ingeniería con cientos de variables (como la optimización de una cadena de suministro), ¿por qué es peligroso confiar en un único punto de inicio aleatorio?**

La función de Himmelblau con solo 2 variables ya tiene 4 mínimos locales. En un problema industrial real — como optimizar una cadena de suministro con costos, tiempos, capacidades y demanda — la función puede tener cientos de variables y miles de mínimos locales. Las estrategias para mitigar este riesgo incluyen: múltiples reinicios aleatorios (random restarts), optimizadores con momentum como Adam que escapan más fácilmente de mínimos locales, y técnicas de búsqueda global como algoritmos evolutivos antes de aplicar gradiente descendente fino.

Fase 3 Redes Neuronales MLP e Hiper Parámetros

Se implementó un Perceptrón Multicapa (MLPRegressor) sobre el dataset Bike Sharing UCI para predecir la demanda horaria de bicicletas (cnt). Se evaluaron métricas de regresión y se optimizaron hiper parámetros mediante GridSearchCV.

Parte A: Evaluación de Métricas de Regresión:

1. Modelo MLPRegressor

Se entrenó el MLP base con early stopping. Los resultados muestran buen poder predictivo y mínima brecha entre train y test, descartando sobreajuste:

Conjunto	MAE	RMSE	R ²
Entrenamiento	47.086	68.547	0.858
Prueba (Test)	47.175	69.458	0.848




Figura 5. Fase 3A: y real vs y pred e histograma de residuales del MLP base (16,8,4)




Figura 6. Fase 3A: Curva de pérdida durante el entrenamiento con early stopping

Preguntas conceptuales Fase 3A

Para finalizar fase 3A, daremos las respuestas a las preguntas conceptuales:

1. ¿Cuál penaliza con mayor severidad los errores grandes: MAE o RMSE?

El MAE promedia los errores absolutos con el mismo peso. El RMSE eleva cada error al cuadrado antes de promediar, lo que hace que los errores grandes contribuyan exponencialmente más:

$$\text{MAE} = (1/n) \times \text{Suma}|y_i - y_{i_pred}| \quad \text{Todos los errores pesan igual}$$

$$\text{RMSE} = \sqrt{(1/n) \times \text{Suma}(y_i - y_{i_pred})^2} \quad \text{Errores grandes pesan mucho mas}$$

Ejemplo: error 10 vs error 100

Contribución al MAE: 10 vs 100 (factor 10x)

Contribución al RMSE: 100 vs 10000 (factor 100x)

El RMSE penaliza más severamente los outliers. En Bike Sharing, un error de 300 bicicletas en hora pico tiene mayor impacto operativo que diez errores de 30. Por eso el RMSE es la métrica más relevante para decisiones logísticas.

2. Diagnóstico: ¿existe sobreajuste en el modelo base?

La brecha entre train y test es mínima: R^2 cae apenas 0.010 puntos (0.858 a 0.848) y el MAE aumenta solo 0.089 unidades. Esto indica que el modelo generaliza correctamente sin sobreajuste.

3. Interpretación de residuos: ¿hay subestimación en demanda alta?

El gráfico y real vs y pred muestra que para $\text{cnt} > 600$, los puntos caen bajo la diagonal ideal: subestimación sistemática en hora pico. El histograma de residuales tiene cola derecha más larga (residuales positivos grandes). Este patrón es típico en modelos de demanda: predicen mejor condiciones normales que picos excepcionales. La subestimación en hora pico es el error más costoso operativamente.

Parte B: Optimización con GridSearchCV

Se ejecutó GridSearchCV con 36 combinaciones x 3 folds = 108 ajustes, variando arquitectura, alpha y learning_rate_init:

```
Ejecutando GridSearchCV (esto puede tardar un poco)...
Fitting 3 folds for each of 36 candidates, totalling 108 fits
Fitting 3 folds for each of 36 candidates, totalling 108 fits
GridSearchCV tomó: 1349.38 s

== Resultado de la búsqueda (CV) ==
Mejores hiperparámetros: {'alpha': 0.01, 'hidden_layer_sizes': (32, 16, 8, 4), 'learning_rate_init': 0.001}
RMSE CV (aprox): 70.9614937560113

== MLP (MEJOR MODELO) ==
Train -> MAE: 42.779 | RMSE: 63.138 | R2: 0.880
Test -> MAE: 45.985 | RMSE: 68.610 | R2: 0.851
```

Mejor arquitectura	Mejor alpha	RMSE CV
(32, 16, 8, 4)	0.01	70.96

Conjunto	MAE	RMSE	R^2
Entrenamiento	42.779	63.138	0.880
Prueba (Test)	45.985	68.610	0.851




Figura 7. Fase 3B: Mejor modelo GridSearch — métricas y y_{real} vs y_{pred}




Figura 8. Fase 3B: Histograma de residuales y curva de pérdida del mejor modelo

Preguntas conceptuales fase 3B

Para finalizar fase 3B, daremos las respuestas a las preguntas conceptuales:

1. **Consistencia de parámetros:** ¿relación entre α óptimo y Ridge Regression?

El GridSearch seleccionó $\alpha = 0.01$. Este parámetro cumple la misma función que λ en Ridge de la Fase 1: penaliza la norma L2 de los pesos de la red. Con $\alpha = 1e-5$ la red sobreajusta (demasiado libre); con $\alpha = 1.0$ subajusta (demasiado penalizada). El valor 0.01 logra el balance óptimo sesgo-varianza. La arquitectura profunda (32,16,8,4) fue preferida sobre la ancha (64,) porque captura mejor las interacciones jerárquicas entre hora, clima y estación que determinan la demanda.

2. Early Stopping: ¿cómo optimiza el tiempo y previene el sobreajuste?

El Early Stopping monitorea el error de validación interna en cada época y detiene el entrenamiento cuando ese error deja de mejorar. En la curva de pérdida (Figura 6) se observa convergencia antes de la época 200. Esto evita memorizar ruido, ahorra tiempo de cómputo y guarda el modelo del mejor momento de validación, no el último entrenado.

3. Conclusión de negocio: ¿es el modelo robusto para decisiones presupuestales?

El mejor modelo tiene $MAE = 45.985$ bicicletas en test. Con una demanda promedio de ~ 190 bicicletas/hora en Washington D.C., el margen de error es $\sim 24\%$. Para redistribución de flota y planificación de turnos este margen es aceptable. Sin embargo, el RMSE de 68.6 bicicletas en escenarios de hora pico indica que para compromisos contractuales de nivel de servicio exacto se requiere un modelo más preciso o datos adicionales (eventos especiales, clima en tiempo real).

Fase 4: Propagación hacia Adelante (Forward Propagation) Manual

Se calcula manualmente la propagación hacia adelante de una red neuronal de 3 capas para clasificar una campaña publicitaria en Bajo Impacto (C1), Impacto Medio (C2) o Impacto Alto (C3). Vector de entrada: $X = [0.5, 0.3, 0.2]^T$.

1. Puntaje de la Capa Oculta (Z(1)):

Notas: DD | MM | AA

①

$$W(1) = \begin{pmatrix} 0,2 & 0,5 & -0,1 \\ 0,8 & 0,3 & 0,4 \\ 0,5 & 0,1 & 0,2 \end{pmatrix}, \quad b(1) = \begin{pmatrix} 0,1 & -0,2 & 0,0 \end{pmatrix}$$

$$X = \begin{pmatrix} 0,5 & 0,3 & 0,2 \end{pmatrix}$$

$$Z_1[1] = 0,2(0,5) + 0,5(0,3) + (-0,1)(0,2) + 0,1$$

$$= 0,10 + 0,15 - 0,02 + 0,10 = 0,33$$

$$Z_1[2] = 0,8(0,5) + (-0,3)(0,3) + 0,4(0,2) + (-0,2)$$

$$= 0,40 - 0,09 + 0,08 - 0,20 = 0,19$$

$$Z_1[3] = (-0,5)(0,5) + 0,1(0,3) + 0,2(0,2) + 0,0$$

$$= -0,25 + 0,03 + 0,04 + 0,00 = -0,18$$

$$Z(1) = [0,33 \quad 0,19 \quad -0,18]$$

2. Activación de la Capa Oculta (A(1)):

Se aplica la función sigmoide $\sigma(z) = 1/(1+e^{-z})$ a cada elemento de Z^1 :

②

$$Z_1 = \sum(Z) = \frac{1}{1 + e^{-(Z)}}$$

$$A_1[1] = \sum 0,33 = \frac{1}{1 + e^{-0,33}} = \frac{1}{1 + 0,7189} = \frac{1}{1,7189} = 0,5818$$

$$A_1[2] = \sum 0,19 = \frac{1}{1 + e^{-0,19}} = \frac{1}{1 + 0,8270} = \frac{1}{1,8270} = 0,5474$$

$$A_1[3] = \sum -0,18 = \frac{1}{1 + e^{0,18}} = \frac{1}{1 + 1,1972} = \frac{1}{2,1972} = 0,4551$$

$$A(1) = [0,5818 \quad 0,5474 \quad 0,4551]$$

3. Puntaje de la Capa de Salida (Z(2)):

③

$$W_2 = \begin{bmatrix} 0,5 & -0,4 & 0,1 \\ 0,2 & 0,8 & -0,5 \\ 0,1 & 0,3 & 0,7 \end{bmatrix} \quad b(2) = \begin{bmatrix} 0,1 & 0,2 & 0,1 \end{bmatrix}$$

$$A(1) = \begin{bmatrix} 0,5818 & 0,5474 & 0,4551 \end{bmatrix}$$

$$z_2[1] = 0,5(0,5818) + (-0,4)(0,5474) + 0,1(0,4551) + (-0,1)$$

$$= 0,2909 - 0,2190 + 0,0455 - 0,1000 = 0,0174$$

$$z_2[2] = 0,2(0,5818) + 0,3(0,5474) + 0,7(0,4551) + 0,2$$

$$= -0,1164 + 0,4379 + 0,2276 + 0,2000 = 0,5267$$

$$z_2[3] = (-0,1)(0,5818) + 0,3(0,5474) + 0,7(0,4551) + 0,1$$

$$= -0,0582 + 0,1642 + 0,3186 + 0,1000 = 0,5246$$

$$Z(2) = \begin{bmatrix} 0,0174 & 0,5267 & 0,5246 \end{bmatrix}$$

4. Probabilidades de Clase (A(2)):

Se aplica la función Softmax para convertir los puntajes en probabilidades que suman 1:

④

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{e^{z_1} + e^{z_2} + e^{z_3}}$$

$$e^{0,0174} = 1,0176$$

$$e^{0,5267} = 1,6929$$

$$e^{0,5246} = 1,6893$$

$$\text{Suma} = 1,0176 + 1,6929 + 1,6893 = 4,3998$$

- $P(C_1 - \text{Bajo Impacto}) = \frac{1,0176}{4,3998} = 0,2316 = 23,1\%$
- $P(C_2 - \text{Medio Impacto}) = \frac{1,6929}{4,3998} = 0,3848 = 38,5\%$
- $P(C_3 - \text{Alto Impacto}) = \frac{1,6893}{4,3998} = 0,3839 = 38,4\%$

} = 1

La red clasifica la campaña como C2 — Impacto Medio (38.5%), con C3 muy cercano (38.4%). La diferencia entre C2 y C3 es de apenas 0.1 puntos porcentuales, indicando alta incertidumbre entre estas dos categorías. La empresa debería tratar esta campaña como de impacto medio-alto.

Preguntas Conceptuales Fase 4.

Para finalizar fase 4, daremos las respuestas a las preguntas conceptuales:

1. Según las probabilidades obtenidas, ¿en qué categoría clasifica la red a esta campaña publicitaria?

Según las probabilidades obtenidas mediante la función Softmax, la red neuronal clasifica esta campaña publicitaria en la categoría C2 - Medio Impacto. Esto debido a que dicha clase presenta el valor exponencial más alto ($e^{z_2} = 1,6929$), lo que se traduce en la probabilidad más elevada al dividir entre la suma total (4,3998), obteniendo $P(C_2) = 0,3848$, superando a $P(C_1) = 0,2316$ y a $P(C_3) = 0,3839$. La regla de decisión en redes neuronales con Softmax establece que la clase ganadora es aquella que maximiza la probabilidad, es decir, $\hat{y} = \text{argmax } P(C_i)$. Aunque la diferencia entre C₂ y C₃ es mínima, el modelo asigna formalmente la campaña a Medio Impacto. Esto sugiere que la red tiene alta incertidumbre entre ambas categorías, lo cual podría ser relevante para la toma de decisiones, ya que una campaña en el límite entre medio y alto impacto requeriría análisis adicionales antes de definir estrategias productivas.

2. ¿Por qué se usa Softmax en la última capa en lugar de sigmoide simple?

La función Softmax garantiza que las salidas sean probabilidades válidas: todas positivas y con suma exactamente igual a 1. Esto es imposible con sigmoide independiente en cada neurona (cada una produce un valor entre 0 y 1, pero su suma puede ser mayor o menor que 1). Además, Softmax crea competencia entre las clases: aumentar la probabilidad de una clase

reduce automáticamente las demás. Esto refleja correctamente que una campaña no puede ser simultáneamente de bajo y alto impacto.

3. ¿Qué sucedería si todos los vectores de sesgo b fueran cero?

Sin bias, cada neurona calcula únicamente combinaciones lineales de sus entradas ($Z = W \cdot X$). Esto implica que cuando todas las entradas son cero, todas las neuronas producen exactamente cero, sin importar los pesos. El sesgo actúa como un umbral ajustable que permite desplazar la función de activación horizontalmente, dando al modelo la flexibilidad de activarse incluso cuando las entradas son pequeñas. Sin él, la red pierde capacidad de representación y le cuesta mucho más aprender patrones donde la clase correcta depende del nivel base de las variables.

Fase 5: Evaluación de Modelos y Toma de Decisiones

Preguntas Fase 5A:




Figura 9. Fase 5: Distribución de Clases

El gráfico de distribución de clases revela un desbalance entre las clases, donde la Clase 0 (No Falla) concentra aproximadamente 9.600 registros frente a apenas ~340 de la Clase 1 (Falla), representando esta última solo el 3.39% del total. Esto refuerza y justifica plenamente la decisión metodológica establecida en el análisis del problema: abandonar el Accuracy como métrica principal y priorizar el Recall de la Clase 1, garantizando que el modelo

capture la mayor cantidad posible de fallos reales aunque genere algunas falsas alarmas, pues en manufactura es siempre preferible una intervención preventiva innecesaria sobre una parada inesperada no detectada.




Figura 10. Fase 5: Torque vs. Velocidad Rotacional

El diagrama de dispersión Torque vs. Velocidad Rotacional evidencia una relación inversa clara entre ambas variables: a mayor velocidad rotacional (rpm), menor es el torque aplicado (Nm), lo cual es físicamente coherente. Lo más relevante desde la perspectiva del Mantenimiento Predictivo es la distribución espacial de los fallos (puntos naranjas, Clase 1): estos se concentran predominantemente en dos zonas extremas, la región de baja velocidad y alto torque y la región de alta velocidad y bajo torque, mientras que en la zona intermedia de operación normal los fallos son escasos.




Figura 11. Fase 5: Distribución de Temperatura del Aire y del Proceso

Las distribuciones de temperatura del aire y del proceso revelan un patrón alarmante en ambas gráficas, los fallos (Clase 1, franja naranja) se distribuyen de manera prácticamente uniforme a lo largo de todo el rango de temperaturas, sin concentrarse en una zona térmica

específica. Esto indica que la temperatura por sí sola, ya sea del aire o del proceso, no es un predictor discriminativo fuerte para anticipar fallos, a diferencia del torque y la velocidad rotacional analizados anteriormente.




Figura 9. Fase 5: Matriz de Confusión - Random Forest

La matriz de confusión del modelo Random Forest muestra de los 1.932 casos reales de "No Falla", el modelo los clasificó correctamente en su totalidad (0 Falsos Positivos), y de los 68 casos reales de "Falla", acertó en 65 con apenas 3 Falsos Negativos. Esto significa que el modelo detecta casi la totalidad de los fallos reales, cumpliendo con la métrica de éxito clave definida, donde un Falso Negativo representa el error más costoso al permitir que una falla ocurra sin anticipación.




Figura 9. Fase 5: Importancia de Variables - Random Forest

El gráfico de Feature Importance del Random Forest confirma y valida el análisis exploratorio previo: Rotational speed y Torque son las variables más determinantes para predecir fallos, con importancias de ~ 0.185 y ~ 0.165 respectivamente. En contraste, las temperaturas del aire y del proceso, que visualmente no mostraban separación entre clases, confirman su bajo poder discriminativo con importancias de apenas ~ 0.040 y ~ 0.025 .




Figura 9. Fase 5: Matriz de Confusión - Red Neuronal

Se clasifica correctamente los 1.932 casos de "No Falla" sin ningún Falso Positivo, y de los 68 fallos reales detecta 66, generando solo 2 Falsos Negativos, lo que se traduce en un Recall de Clase 1 $\approx 97,1\%$ ($66/68$).

Preguntas Fase 5 A:

- 1. Si el modelo indica que los errores en la Clase 1 (Fallo) pesarán aproximadamente 14.7 veces más que en la Clase 0, ¿qué intenta corregir el algoritmo al configurar el parámetro class weight durante el entrenamiento?**

Al configurar un class_weight donde los errores de la Clase 1 pesan 14.7 veces más que los de la Clase 0, el algoritmo intenta corregir el severo desbalance del dataset (donde los fallos representan apenas el 3.39% de los datos). Sin esta ponderación, el modelo tendería a ignorar casi por completo la clase minoritaria (Falla) y clasificar todo como "No Falla". Al penalizar 14.7 veces más los errores en fallos, el modelo se ve "forzado" a prestar mayor atención a esos casos escasos, priorizando la reducción de Falsos Negativos sobre los Falsos Positivos.


2. Explique por qué en este caso un Accuracy del 95 % podría considerarse un resultado deficiente para la gestión de mantenimiento si el modelo no logra detectar los fallos reales.

Un Accuracy del 95% puede ser engañoso y completamente insuficiente en este contexto porque, dado que el 96.6% de los datos corresponden a "No Falla", un modelo que simplemente prediga siempre esa clase sin aprender ningún patrón real de fallo alcanzaría ese porcentaje de exactitud de forma trivial. En la gestión de mantenimiento industrial, lo verdaderamente costoso no es una falsa alarma sino un **Falso Negativo**: que el modelo diga "No Falla" cuando la máquina sí va a fallar implica una parada no planificada con cuellos de botella, retrasos en entrega y costos de reparación urgentes que superan con creces el costo de una intervención preventiva innecesaria. Por tanto, un modelo con 95% de accuracy pero Recall bajo en Clase 1 sería prácticamente inútil para el propósito real del Mantenimiento Predictivo.

Matriz Fase 5 - Análisis Complementario.


Suponga que para su planta de producción, el costo de una reparación no planificada (Fallo Real no detectado) es de USD 5,000 y el costo de una inspección preventiva innecesaria (Falsa Alarma) es de USD 200.

Datos Iniciales.



TN = 1932	→ Verdaderos Negativos
FP = 0	→ Falsos Positivos
FN = 2	→ Falsos Negativos
TP = 66	→ Verdaderos Positivos


1. ¿Qué tan confiable es el modelo cuando emite una alerta de falla?



Handwritten calculation of Precision on a grid background. It shows the formula $Precisión = \frac{TP}{TP + FP}$ with values $\frac{66}{66 + 0}$ and the final result $\frac{66}{66} = 1 = 100\%$. A circled number 1 is in the top left corner.

Cuando el modelo emite una alerta de falla, tiene una confiabilidad del **100%**: cada alarma generada corresponde a un fallo real, sin falsas alarmas.

2. ¿Qué porcentaje de los fallos reales totales logró capturar el modelo?




Handwritten calculation of Recall on a grid background. It shows the formula $Recall = \frac{TP}{TP + FN}$ with values $\frac{66}{66 + 2}$ and the final result $\frac{66}{68} = 0,9706 = 97,06\%$. A circled number 2 is in the top left corner.

El modelo logra capturar el 97.06% de todos los fallos reales, dejando pasar únicamente 2 fallos sin detectar.

3. Calcule el impacto económico mensual del modelo utilizando la fórmula:

$$\text{Costo} = (FN \times 5000) + (FP \times 200)$$



Handwritten calculation of the monthly cost on a grid background. It shows the formula $\text{Costo} = (FN * 5000) + (FP * 200)$, then substitutes values $\text{Costo} = (2 * 5000) + (0 * 200)$, and finally calculates $\text{Costo} = 10.000 + 0 = \$10.000 \text{ USD mensuales}$. A circled number 3 is in the top left corner.

Este resultado es favorable, al no generar ningún falso positivo ($FP=0$), el único costo proviene de los 2 fallos no detectados. Comparado con un modelo sin Mantenimiento Predictivo que no detectara ninguno de los 68 fallos reales, un error que costaría 340.000 USD mensuales, la Red Neuronal representa un ahorro del 97.06% en costos de errores.

Preguntas Conceptuales Fase 5.

1. ¿Preferiría usted un modelo con un Recall del 98 % pero una Precisión del 60 %, o viceversa?

En el contexto de paradas de línea críticas, se preferiría el modelo con **Recall del 98%** y **Precision del 60%**, aunque esto genere más Falsos Positivos. Un Falso Negativo cuesta \$5.000 USD, mientras que una Falsa Postivo cuesta apenas USD \$200. Con Precisión del 60%, por cada 10 alertas emitidas, 4 serían falsas alarmas con un costo de \$800, pero se estarían capturando casi todos los fallos reales. En contraste, sacrificar Recall para ganar Precisión significa permitir que más fallos pasen desapercibidos, cada uno con un impacto 25 veces mayor que una inspección innecesaria, lo que resulta económicamente insostenible en manufactura.

2. ¿Considera que 30 épocas son suficientes para que el modelo converja? ¿Qué sucede con el error de validación comparado con el de entrenamiento?

Las 30 épocas pueden ser suficientes si la curva de pérdida de entrenamiento y validación convergen establemente hacia valores bajos sin oscilaciones significativas. Sin embargo, si el error de validación comienza a aumentar mientras el de entrenamiento continúa disminuyendo, estaríamos ante overfitting, señal de que el modelo memoriza los datos de entrenamiento sin generalizar bien. Dado el desbalance del dataset, es fundamental monitorear no solo el accuracy sino el Recall en validación, pues un modelo puede mostrar curvas de pérdida aparentemente buenas pero seguir fallando en detectar la clase minoritaria.

3. ¿Cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa de manufactura?

El uso de métricas avanzadas como el Recall transforma radicalmente la rentabilidad de una empresa manufacturera porque cambia el enfoque de qué tan preciso es el modelo en general a qué tan bien detecta exactamente lo que más cuesta. Como se demostró, un modelo optimizado por Recall que detecta el 97% de fallos reales reduce el costo mensual de errores

de USD \$340.000 (sin modelo) a apenas \$10.000, representando un ahorro del 97%. Esto convierte al Mantenimiento Predictivo basado en métricas correctas en una ventaja competitiva real, permitiendo planificar intervenciones, optimizar inventarios de repuestos y eliminar paradas no planificadas que erosionan márgenes y reputación productiva.

Conclusiones.

1. Las redes profundas resultan más adecuadas que las arquitecturas anchas porque permiten modelar las interacciones jerárquicas entre variables de proceso. En sistemas industriales, donde los fenómenos ocurren en cadenas de causalidad, elegir una arquitectura simplificada equivale a ignorar la naturaleza real del sistema y comprometer la capacidad predictiva..
2. En entornos desbalanceados, el uso de métricas como Recall es más relevante que el Accuracy, pues lo crítico no es acertar en la clase mayoritaria, sino detectar los fallos raros y costosos. Optimizar por sensibilidad transforma directamente la rentabilidad: Reduce paradas inesperadas, evita pérdidas monetarias y convierte el mantenimiento predictivo en una ventaja competitiva. La elección de la métrica deja de ser un detalle técnico y se convierte en una decisión estratégica con impacto económico tangible en las compañías.
3. Integración de técnicas de entrenamiento como garantía de utilidad real Mecanismos como *Early Stopping* que asegura que el modelo conserve su capacidad de generalización y *class_weight* que corrige el sesgo estructural de datasets desbalanceados, estos son esenciales para que las redes neuronales en manufactura sean aplicables en producción, su combinación no es una condición indispensable para que el modelo aporte valor operativo en escenarios donde los fallos son raros pero extremadamente costosos.

Referencias Bibliográficas.

- Guevara-Tirado, A. (2025). Implementación de redes neuronales para la predicción del síndrome metabólico: un estudio con datos multinacionales. *Gaceta Médica de México*, 161(3), 215–223. <https://doi.org/10.24875/gmm.24000411>
- Guevara Gómez, M. L. (2023). Clasificación de eventos de calidad de energía utilizando redes neuronales convolucionales profundas en el marco de la industria 4.0.
- Blanco, L. C., Casas, L., González, O. L. P., & Mota, Y. C. (2015). Redes neuronales artificiales en la producción de tecnología. *Revista Academia y Virtualidad*, 8(1), 12-20.
- Muñoz San Roque, A. (1996). Aplicación de técnicas de redes neuronales artificiales al diagnóstico de procesos industriales.
- Matich, D. J. (2001). *Redes Neuronales: Conceptos básicos y aplicaciones*. Universidad Tecnológica Nacional, México, 41, 12-16.
- Perdigón Llanes, R., & González Benítez, N. (2021). Redes neuronales artificiales en el pronóstico de la producción de leche bovina.
- Mendoza-Haro, I., & Marquetti-Nodarse, H. (2019). Redes Neuronales Artificiales: factores que determinan la cosecha de caña en la industria azucarera. *Revista Ciencia UNEMI*, 12(29), 36-50.
- Servín-Palestina, M., Salazar-Moreno, R., López-Cruz, I. L., Medina-García, G., & Cid-Ríos, J. A. (2022). Predicción de la producción y rendimiento de frijol, con modelos de redes neuronales artificiales y datos climáticos. *Biotecnia*, 24(2), 104-111.
- de Jesús Calderón-Sánchez, J., Granillo-Macías, R., Robles, F. S., & Rivera-Gómez, H. (2025). Aplicación de redes neuronales en la industria siderúrgica. *Research, Society and Development*, 14(4), e8014448712-e8014448712.

- Moposita, J. D., Pujos, D. G., Ramírez, S. M., & Archig, R. S. (2024). Aplicación de redes neuronales en el análisis de gases disueltos para el mantenimiento preventivo de transformadores de potencia. *Revista Ibérica de Sistemas e Tecnologías de Informação*, (E73), 312-327.
- Block, J. M. (2003). Formulación de grasas a través de redes neuronales: productos comerciales y producción en planta piloto. *Grasas y aceites*.
- Laguna, R., Geremías, N., Chiruzzo, L., Maiuri, D., Rodriguez, J., Gutierrez, A., & Cataldo, J. (2019). Desarrollo de herramientas para mantenimiento predictivo de aerogeneradores en base a redes neuronales. In *II Congreso de Agua, Ambiente y Energía* (pp. 1-9).
- Gómez, J. R., Monteagudo, J. P., & Ramos, F. (2009). Diagnóstico del mantenimiento centrado en la eficiencia de turbinas de contrapresión aplicando redes neuronales artificiales.
- Isis, B. C., Sain, S. M., Abdel, R. A., balo Ricardo, G. Ã., & Matilde, G. L. M. (2007). Redes neuronales recurrentes para el análisis de secuencias: Redes neuronales recurrentes para el análisis de secuencias. *Revista Cubana de Ciencias Informáticas*, 1(4).
- Larranaga, P., Inza, I., & Moujahid, A. (1997). Tema 8. redes neuronales. *Redes Neuronales*, U. del P. Vasco, 12, 17.